

TOPOLOŠKA ANALIZA PODATAKA

JOVANA LAZIĆ 21/2022
LAZAR JOVANOVIĆ 69/2022

Jun 2026.

SADRŽAJ

Uvod	1
Perzistentna homologija	2
Osnovna ideja	2
Igračka primer	4
MNIST	5
Mapper algoritam	6
Osnovna ideja	6
Pubmed	6
Primena mapper algoritma	6
Perzistentna homologija na PubMed skupu	9
Lokalna perzistentna homologija okolina	9
Poređenje modela	10
Da li je poboljšanje stvarno?	11
Strukturna perzistentna homologija citatnih mreža	12
Deskriptivno poređenje klasa	14
Bogatiji feature-i, pretraga i objedinjeni model	15
Zaključak	17

Uvod

Topologija je grana matematike nastala apstrahovanjem metrike iz metričkog prostora ostavivši iza sebe samo opšti pojam bliskosti. Ugrubo se bavi klasifikovanjem skupova po različitim inherentnim osobinama tih skupova - tzv. topološkim invarijantama.

Definicija 1 . Uređen par (X, τ_X) koji čine neprazan skup X i kolekcija svih otvorenih podskupova sadržanih u njemu τ_X zovemo *topološkim prostorom*.

Napomena. τ_X zovemo *topologijom prostora*. Često i sam skup X zovemo topološkim prostorom kada je τ_X implicitno zadato ili poznato.

Definicija 2 . Funkciju $f : X \rightarrow Y$ zovemo *neprekidnom* ako $(\forall y \in \tau_Y) f^{-1}(y) \in \tau_X$. Odnosno, ako je inverzna slika svakog otvorenog skupa u Y otvoren skup u X .

Definicija 3 . Ako za topološke prostore X i Y postoji preslikavanje $f : X \rightarrow Y$ takvo da važi:

1. f je neprekidna funkcija
2. f je bijekcija
3. f^{-1} je neprekidna funkcija

tada za X i Y kažemo da su *homeomorfni* u oznaci $X \approx Y$ a f zovemo *homeomorfizam*.

Svaka osobina prostora koja je invarijanta u odnosu na homeomorfizme zovemo *topološkim invarijantama*. Ispostaviće se da baš one hvataju našu intuiciju o oblicima (mada je neretko i ruše). Svaki trougao nezavisno od geometrijske realizacije (kako ga nacrtamo) će ostati trougao te po mnogo čemu biti sličan bilo kom drugom trouglu na koji možemo naići. Topološka analiza podataka se upravo bavi ekstrahovanjem značajnih topoloških invarijanti prostora podataka na osnovu kojih se prave bolji klasifikatori. U cilju izračunavanja topoloških invarijanti, služićemo se algebarskom topologijom.

Proći ćemo dve najčešće metode topološke analize podataka:

1. perzistentnu homologiju
2. mapper algoritam

U nastavku podrazumevamo da radimo sa očišćenim podacima koji žive u $\mathbb{R}^n$. Biblioteka računarske topologije koju ćemo koristiti je [Giotto TDA](#).

PERZISTENTNA HOMOLOGIJA

OSNOVNA IDEJA

Homologija prostora ima za cilj da uhvati "rupe" tog prostora određene dimenzije. Kako znamo da se nalazimo u nekom potprostoru od $\mathbb{R}^n$, najveća moguća dimenzija rupe će biti za jedan manja odnosno $n - 1$. U praksi, retko kada se traže rupe dimenzije veće od 1 a skoro nikad veće od 2, kako zbog računske složenosti, tako i zbog do sada ne dokazanog benefita same potrage.

Naći rupu u nekakvom opštem prostoru koji nam nije unapred zadat niti ga savršeno opažamo ne možemo ni u jednom smislu naći direktno. Potrebno nam je nekakvo pojednostavljenje koje će ipak zadržati to što tražimo. Odnosno, potrebno nam je da naša definicija rupe bude topološka invarijanta kao i homeomorfan prostor u kome znamo da je nađemo. Ispostavilo se da su *simplicijalni kompleksi* pogodni u ove svrhe.

Definicija 4. Neka su $u_0, u_1, \dots, u_k \in \mathbb{R}^n$. Tačku $x = \sum_{i=0}^k \lambda_i u_i$ za $\lambda_i \in \mathbb{R}$ nazivamo *afinom kombinacijom*. Za tačke u_i kažemo da su *afino nezavisne* odnosno u *opštem položaju* ako su vektori $u_i - u_0, i = 1..k$ linearno nezavisni. Afinu kombinaciju u kojoj su $\lambda_i \geq 0$ zovemo *konveksnom kombinacijom*.

Definicija 5. k -simpleks σ jeste skup svih konveksnih kombinacija $k + 1$ afino nezavisnih tačaka u oznaci $\sigma = \text{conv}\{u_0, u_1, \dots, u_k\}$. Dimenzija simpleksa je $\dim \sigma = k$.

Definicija 6. Ako je $\sigma = \text{conv}\{u_0, u_1, \dots, u_k\}$ simpleks i $\{v_0, v_1, \dots, v_l\} \subseteq \{u_0, u_1, \dots, u_k\}$ tada je $\tau = \text{conv}\{v_0, v_1, \dots, v_l\}$ stranica simpleksa σ u oznaci $\tau \leq \sigma$.

Definicija 7. *Simplicijalni kompleks* jeste konačna kolekcija simpleksa K takva da:

- $(\forall \sigma \in K)(\forall \tau \leq \sigma) \tau \in K$
- $(\forall \sigma, \tau \in K) \sigma \cap \tau = \emptyset \vee \sigma \cap \tau \leq \sigma, \tau$


Odnosno, svaka stranica svakog simpleksa simplicijalnog kompleksa jeste simpleks tog simplicijalnog kompleksa i svaka dva simpleksa u kompleksu su ili disjunktna ili imaju zajedničku stranu. Dimenzija simplicijalnog kompleksa $\dim K = \max\{\dim \sigma \mid \sigma \in K\}$.

Kako naši podaci žive u $\mathbb{R}^n$ i formiraju tzv. *oblak tačaka* (point cloud), a mi želimo da radimo sa simplicijalnim kompleksima, potrebno je nekako preći iz jednog oblika u drugi. Zapravo, oblak tačaka jeste jedan simplicijalni kompleks jer je svaka tačka simpleks za sebe. Jasno je doduše da takav kompleks ne nosi sa sobom puno značajne informacije o bilo kakvim rupama (naime, rupa nema). Da li onda možemo nekako grupisati tačke u veće simplekse pa tu pronaći rupe?


Koliko uopšte treba povećavati simplekse i kojim rupama uopšte dati na značaju dok nastaju i nestaju? Odgovori na sva ova pitanja nam zapravo daju samu tehniku koju razmatramo.

Prvi sastojak je odabir kompleksa.


Definicija 8 . Neka je $S \subset \mathbb{R}^n$ neki skup tačaka i $r \in \mathbb{R}$. *Vietoris-Ripsov* kompleks je: $VR(r) := \{\sigma \subseteq S \mid \text{diam}(\sigma) \leq 2r\}$. Odnosno, to je simplicijalni kompleks izgrađen od simpleksa koji svi staju u lopte poluprečnika r .




VR(0)



VR(3.2)



VR(4.5)



VR(7)

Slike su napravljene pomoću [geogebra](#) apleta.

Drugi sastojak je pojam *filtracije*. Primetimo da je $VR(0)$ samo naš polazni oblak tačaka dok je $VR(\infty)$ zapravo samo jedan simpleks unutar kompleksa. Kako je sam oblak tačaka konačan, tako će i broj potrebnih koraka (odnosno parametara $r_1, r_2, \dots$) biti konačan. Filtracijom ćemo zvati niz kompleksa $K_0 \subseteq K_1 \subseteq K_2 \subseteq \dots \subseteq K_n$ koji smo dobili povećavanjem parametra r . Nije nužno da kompleks koji koristimo bude baš Vietoris-Ripsov, koriste se i Čehov i Alfa kompleks.

Poslednji sastojak dobijamo odgovorom na pitanje koje rupe treba da vrednujemo: one koje najduže opstanu. Otuda i naziv i poenta same metode. Ostaje još definisati homologiju simplicijalnog kompleksa i način da je izračunamo.

Definicija 9 . Lančasti kompleks (C_*, d_*) jeste kolekcija Abelovih grupa $C_* = \{C_n\}_{n \in \mathbb{Z}}$ zajedno sa familijom preslikavanja $d_* : \{d_n : C_n \rightarrow C_{n-1}\}_{n \in \mathbb{Z}}$ takvih da je $d_{n-1} \circ d_n = 0, \forall n \in \mathbb{Z}$.

Definicija 10 . Neka je (C_*, d_*) lančasti kompleks i neka je n ceo broj. $Z_n = \ker d_n$ i $B_n = \text{im } d_{n+1}$ zvaćemo n -ciklovima i n -granicama.

Napomena. Iz algebre znamo da $Z_n, B_n \leq C_n$ a dodatno važi i $B_n \leq Z_n$ jer $d_n \circ d_{n+1} = 0$.

Definicija 11 . n -ta homologija lančastog kompleksa (C_*, d_*) jeste $H_n(C_*) = Z_n/B_n$

Homologija simplicijalnih kompleksa se definiše preko homologije lančastih kompleksa (koje nećemo za sada komentarisati) te ih moramo uvesti. U nastavku podrazumevamo da je K simplicijalni kompleks, $n \in \mathbb{N}_0$ i G grupa.

Definicija 12 . n -lanac sa koeficijentima u G je formalna suma n -simpleksa odnosno $c = \sum_{i=1}^k a_i \sigma_i$ gde je $\dim \sigma_i = n$ i $a_i \in G$. Za dva n -lanca $c_1 = \sum_{i=1}^k a_i \sigma_i$ i $c_2 = \sum_{i=1}^k b_i \sigma_i$ definišemo $c_1 + c_2 = \sum_{i=1}^k (a_i + b_i) \sigma_i$ kao i $0 = \sum_{i=1}^k 0 \sigma_i$. Sa C_n obeležimo grupu n -lanaca nastalu na ovaj način.

Definicija 13 . Definišimo $d_n : C_n \rightarrow C_{n-1}$ nad generatorima n -lanaca grupe C_n kao $d_n(\sigma) = \sum_{i=0}^k (-1)^i [u_0, u_1, \dots, \hat{u}_i, \dots, u_k]$ gde su u_i 0 -simpleksi (tačke) simplicijalnog kompleksa K a sa $\hat{u}_i$ označavamo da smo izbacili i -to teme.

Teorema 1 . Ovako definisani (C_*, d_*) formiraju lančasti kompleks.

Definicija 14 . Homološke grupe simplicijalnog kompleksa K definišemo kao homološke grupe lančastog kompleksa određenog sa K .

Kakve ovo veze ima s rupama? Ideja je u tome da umesto da tražimo samu rupu, mi nađemo njen obod. Operator d_n je zapravo operator granice u dimenziji n . Smisao uslova $d_n \circ d_{n-1} = 0$ leži u činjenici da granica granice jedne dimenzije mora biti trivijalna. Zašto Z_n sećemo sa B_n ? Z_n čini grupu svih elemenata koji graničnim operatorom idu u nulu ali elementi koji su činili granicu u prethodnoj dimenziji nužno idu u nulu te u tom smislu nisu bitni. Ono što nam ostaje u količničkoj grupi su zapravo n -lanci koji nisu granica ničega. Odnosno, oni su baš granica rupe.

Definicija 15 (Betijevi brojevi) . $\beta_n = \text{rank } H_n$

U praksi se za G uzima grupa $\mathbb{Z}_2$. Prednost je ta što je izuzetno lako i brzo za računanje koeficijenata kao i Betijevih brojeva.

IGRAČKA PRIMER

Prvi primer da se uverimo da sve ovo možda nećemu služi jeste da klasifikujemo neke osnovne topološke prostore po njihovim homološkim grupama. Klasifikovaćemo kružnice S^1 , sfere S^2 i toruse T^2 .

Prostor	H_0	H_1	H_2
S^1	$\mathbb{Z}$	$\mathbb{Z}$	0
S^2	$\mathbb{Z}$	0	$\mathbb{Z}$
T^2	$\mathbb{Z}$	$\mathbb{Z} \oplus \mathbb{Z}$	$\mathbb{Z}$

Homološke grupe S^1 , S^2 i T^2

Ovo je dobro mesto na konkretnom primeru da vidimo šta svaka homološka grupa zapravo znači. H_0 konkretno broji komponente povezanosti prostora. Svako $\mathbb{Z}$ koje učestvuje u direktnoj sumi kojoj je H_0 izomorfna odgovara jednoj komponenti povezanosti. Kao što vidimo iz tabele, sva tri prostora imaju samo jedno $\mathbb{Z}$ odnosno jednu komponentu povezanosti što i očekujemo. Samim tim, nije nam potrebno da je izračunamo da bismo razlikovali ove prostore ali to svakako uraditi da se uverimo.

H_1 je prva prava rupa i misli se na jednodimenzionu rupu, baš onakvu kakvu kružnica zatvara. Sfera S^2 nema nijednu kružnicu koju ne možemo da skupimo u tačku pa je njena H_2 trivijalna. Torus T^2 ima dve takve disjunktne klase kružnica:

1. prva ide oko unutrašnjosti torusa
2. druga ide oko centra torusa

Kružnica S^1 je dvodimenzion prostor pa samim tim ne može imati dvodimenzionu rupu. Sfera S^2 i torus T^2 oba zatvaraju po jednu trodimenzionu šupljinu.

Vietoris-Ripsov perzistentni dijagram pravimo na sledeći način:

```
from gtdata.homology import VietorisRipsPersistence

VR = VietorisRipsPersistence(homology_dimensions=[0, 1, 2])
diagrams = VR.fit_transform(point_clouds)
```

Dijagrami su grafici na kojima se za svaku homološku grupu koju smo naveli beleže vreme nastajanja (birth) i vreme umiranja (death) izražene preko vrednosti parametra r Vietoris-Ripsovog kompleksa. Dijagrami sami za sebe nisu pogodni kao feature za klasifikator te ćemo koristiti *perzistentnu entropiju*.

Definicija 16. Za perzistentni dijagram $D = \{(b_i, d_i) \mid d_i \neq \infty\}_{i \in I}$, perzistentna entropija jeste

$$E(D) := - \sum_{i \in I} p_i \log p_i \text{ gde je } p_i := \frac{d_i - b_i}{\sum_{j \in I} d_j - b_j}$$

Perzistentnu entropiju računamo lako:

```
from gtdata.diagrams import PersistenceEntropy

PE = PersistenceEntropy()
features = PE.fit_transform(diagrams)
```

Features ostaje samo matrica brojeva koja je pogodna za treniranje klasifikatora na koje smo navikli. Koristićemo `RandomForestClassifier` iz `sklearn` biblioteke.

U pratećem jupyter notebooku vidimo da i sa i bez uključivanja H_0 model bez greške razlikuje oblike, što si očekuje na ovakom primeru.

MNIST

I ako jeste mačiji kašalj za konvolutivne neuronske mreže (CNN), problem prepoznavanja rukom pisanih cifara sa slika nije naivan problem i uglavnom se ne rešava dobro klasičnim metodama mašinskog učenja. Međutim, eksploatacijom perzistentne homologije, moguće je dobiti [pristojne rezultate](#). Jedna implementaciju rada se nalazi [ovde](#).

MAPPER ALGORITAM

OSNOVNA IDEJA

Mapper algoritam služi da prevede visokodimenzionalne point cloudove u grafovsku reprezentaciju koja je dovoljno male dimenzije da bude pogodna za vizualizaciju ili samo treniranje modela. Sastoji se od četiri suštinska koraka:

1. filtracija - nekim od postojećih algoritama redukcije dimenzionalnosti (često PCA) podatke spuštamo u nižu dimenziju (često 1 ili 2)
2. binovanje - delimo dobijen prostor niže dimenzije u preklapajuće intervale (odnosno pravimo konačan pokrivač nad podacima)
3. klusterizacija - tačke pojedinačnih intervala klasterujemo na osnovu njihovih visokodimenzionalnih osobina iz polaznog skupa podataka
4. konstrukcija grafa - svaki klaster je čvor a ivice dodajemo između svih klastera koji imaju zajedničku tačku (to je moguće zbog načina na koji smo podelili intervale)

PUBMED

Demonstriraćemo moć i bolje pojasniti teorijske osnove samog algoritma nad skupom podataka *PubMed*. U pitanju je kolekcija naučnih članaka iz oblasti medicine koji su povezani citatima a predstavljeni svojim tf-idf vektorom. Najčešći zadatak nad ovim skupom jeste klasifikacija. Najsavremeniji pristup rešavanju ovog zadatka nad ovim skupom podataka pružaju grafovske neuronske mreže (GNN) zasnovane na metodu prosleđivanja poruka (message passing). Koliko god pokušavali, klasičnim metodama uz dodatak TDA ga nećemo nadmašiti no to i nije toliko strašno jer ga ništa u skorije vreme ni neće nadmašiti.

PubMedu se može pristupiti bez ikakve upotrebe topologije podataka i to ćemo koristiti kao polaznu tačku. Cilj je da ispitamo koliko povezanost odnosno citati mogu doprineti konačnom modelu. Za tu početnu ocenu ćemo uzeti bolji između `SVC` i `RandomForestClassifier` iz `sklearn` biblioteke. Vidimo da je slučajna šuma nešto malo bolja od metode potpornih vektora. Naravno, mogu se modeli dodatno štelovati pretragom po rešetki (grid search) no to nije poenta te se nećemo zadržavati.

PRIMENA MAPPER ALGORITMA

Videli smo u uvodu da imamo određene izbore da napravimo kada koristimo mapper. Prvi je filter funkcija koja se nekad zove i sočivo (lens). Kako imamo suštinski dva različita modaliteta

podataka (tf-idf vektore i strukturu citata), deluje smisleno da redukujemo podatke u dve dimenzije: jednu po modalitetu.

Prva dimenzija će biti PageRank čvora a druga najveća SVD komponenta tf-idf matrice. Pošto radimo sa grafom od 19000 čvorova, neke komplikovanije osobine kao što je centralnost nisu praktične. PageRank se računa relativno brzo a istorijski jeste informativna karakteristika čvora. SVD/PCA nad tf-idf matricom je relativno česta stvar koju verujem da nema potrebe objašnjavati (latentna semantička analiza).


Drugi izbor koji pravimo jeste odabir intervala. Ovo je deo koji zahteva malo sreće ili malo pretrage po rešetki (grid search) koju suštinski nije moguće uraditi u nekom normalnom vremenskom roku zbog trajanja izvršavanja jednog prolaza kroz algoritam. Ipak, probali smo više kombinacija, nije se ispostavilo da pravi značajnu razliku.

Treći izbor je odabir algoritma klasterovanja i njegovih parametara. U literaturi se najčešće koristi DBScan. To je iz razloga što ne pravi jake pretpostavke o obliku podataka za razliku od drugih metoda (recimo k-means koji pretpostavlja globularne klastere). Odabir za epsilon i broj instanci bi trebalo potkrepiti ponovo pretragom po rešetki koju ne možemo uraditi u razumnom vremenu te smo probali par kombinacija bez nekog naročitog boljitka. Metrika koju ćemo koristiti je kombinovana metrika pojedinačnih koordinata:

$$D(X, Y) := \alpha D_{G(X,Y)} + (1 - \alpha) D_{T(X,Y)}$$

gde je D_G najkraće netežinsko rastojanje od X do Y dok je D_T kosinusno rastojanje tf-idf reprezentacija čvorova. Uzeli smo $\alpha = 0.4$ logikom da je sadržaj samog rada bitniji od toga ko ga citira.

Finalni kod za ovaj konkretan pipeline ima puno tehničkih detalja koji nisu naročito zanimljivi za objašnjavanje a ni previše bitni. Konačan graf koji smo dobili mapper algoritmom je:



Boje označavaju koliko se dobro agregirani radovi slažu sa prvom SVD komponentom tf-idf matrice koju smo koristili prilikom filtriranja. Što je broj veći, više prate najopštiju semantičku

temu prisutnu u podacima. Odnosno, što je broj manji, to pričamo o specifičnijim radovima koji verovatno koriste neki vrlo usko specifični žargon i slično.

Pristustvo jedne velike komponente povezanosti okružene mnoštvom manjih signalizira da imamo jednu veliku bazu dobro semantički i strukturno povezanih radova kao i dobar broj manjih samostalnih zajednica. Ovo mogu biti i klasteri od po jednog dva rada koji nisu mnogo citirani ili radovi koji koriste reči koje su se pojavile izuzetno mali broj puta i slično. Ono što nam se ne sviđa u ovom grafu jeste što ništa od ovoga nije naročito neočekivano. Kada bismo morali da nagađamo kako izgleda, nešto bismo ovako i zamišljali. U kontekstu konvertovanja samog grafa u nove feature-e kojim bismo pojačali našu slučajnu šumu, ne nadamo se previše.

Kako uopšte da napravimo neki feature od ovog grafa?

Ovo nije jednostavno pitanje i može verovatno još jedan ceo tekst da se napiše koji obrađuje samo njega. Umesto toga, možemo primetiti da svaki dokument pripada jednom ili više čvorova mapper grafa i samu tu pripadnost možemo tretirati kao feature-e.

Konačno, kada uporedimo metrike slučajne šume sa i bez našeg silnog truda, vidimo da ispada bolje da nismo ništa radili.

Zašto?

Odgovor leži u sledećem: sami feature-i ne pružaju značajno veću količinu informacije u odnosu na njihovu veličinu. Naime, što više parametara stablo odlučivanja pa samim tim i nasumična šuma ima na raspolaganju, to im je teže da naprave dobra razdvajanja prostora. Kada pogledamo najvažnije feature-e jedne i druge šume, primećujemo da su skoro pa isti osim što u novoj šumi imamo i naše topološke feature-e koji očitó ne generalizuju dobro na test podacima.

Sam mapper algoritam ima zaista veliku primenu u nauci, samo očitó zahteva malo više znanja da bi se dobro iskoristio.

PERZISTENTNA HOMOLOGIJA NA PUBMED SKUPU


Mapper nam je dao jedan topološki pogled na PubMed. Prirodno je zapitati se da li i perzistentna homologija, drugi stub topološke analize podataka, može da izvuče korisnu informaciju iz istog skupa. Za razliku od igračka primera iz druge glave, gde smo klasifikovali cele oblake tačaka (kružnice, sfere, toruse), ovde je zadatak klasifikacija čvorova (radova), pa nam trebaju topološke karakteristike po čvoru, analogne pripadnostima mapper grafu iz prethodne glave.

LOKALNA PERZISTENTNA HOMOLOGIJA OKOLINA

Za svaki rad i posmatramo njegovu citatnu okolinu, to jest sam rad zajedno sa svim radovima sa kojima je povezan citatom. Tf-idf vektori te okoline čine mali oblak tačaka u $\mathbb{R}^{500}$ nad kojim gradimo Vietoris-Ripsov perzistentni dijagram (dimenzije 0 i 1), koristeći kosinusno rastojanje D_T isto kao u mapper poglavlju. Iz dobijenog dijagrama izvlačimo šest karakteristika po čvoru:

- logaritam stepena čvora (veličina okoline),
- perzistentnu entropiju u dimenziji 0 i 1 (PE_{H_0} , PE_{H_1}),
- broj i najveću trajnost jednodimenzionih rupa,
- ukupnu trajnost nula-dimenzionih klasa (mera raširenosti okoline).

Perzistentnu entropiju uvodimo isto kao u drugoj glavi, ona sažima raspodelu trajnosti u dijagramu u jedan broj. Ceo proračun za svih 19717 čvorova traje svega nekoliko sekundi jer su okoline male.



Perzistentni dijagram citatne okoline jednog rada. H_0 tačke leže na osi birth = 0, a H_1 tačke su nagurane uz dijagonalu, kratkoživeće petlje bez izražene rupe.

Već sam dijagram nagoveštava problem: jednodimenzione klase (H_1) skoro sve leže tik uz dijagonalu, što znači da su to kratkoživeće petlje (topološki šum), a ne stvarne rupe u podacima. Citatne okoline u tf-idf prostoru nemaju bogatu topologiju.

POREĐENJE MODELA

Kao i kod mappera, polazna tačka su `RandomForestClassifier` i `SVC` na čistim tf-idf vektorima, a zatim tf-idf-u dodajemo šest topoloških karakteristika. Sve modele ocenjujemo na istoj train/test podeli (`random_state=42` , 20% za test, 3944 radova). Za razliku od koda iz mapper sveske koji je štampao binarnu konfuzionu matricu, ovde dajemo pravu višeklasnu ocenu po sve tri klase.


Model	Tačnost	Makro F1
RF na tf-idf	0.8884	0.8871
SVC na tf-idf	0.8798	0.8794
RF samo na PH karakteristikama	0.4108	0.3207
RF na tf-idf + PH	0.8935	0.8924

Ukupno poređenje na fiksnoj podeli.

Same PH karakteristike nose vrlo malo informacija, model treniran isključivo na njima jedva prevazilazi pogađanje većinske klase (koja čini oko 40% skupa). U kombinaciji sa tf-idf-om, na ovoj podeli, kombinovani model deluje malo bolji od baseline-a, i to ravnomerno po svim klasama:

Klasa	F1 (tf-idf)	F1 (tf-idf + PH)	Razlika
Klasa 0	0.8803	0.8867	+0.0064
Klasa 1	0.8988	0.9057	+0.0069
Klasa 2	0.8823	0.8848	+0.0025

F1 mera po klasama na fiksnoj podeli.



F1 po klasama: baseline naspram dodatih PH karakteristika (fiksna podela).

DA LI JE POBOLJŠANJE STVARNO?


Razlika od pola procenta je vrlo mala i lako može biti posledica jednog povoljnog izbora podele. Zato radimo uparenu unakrsnu validaciju (RepeatedStratifiedKFold, 5 foldova puta 2 ponavljanja): u svakom foldu treniramo oba modela na istim podacima i poredimo ih uparenim t-testom.

Model	Tačnost ($\mu \pm \sigma$)	Makro F1 ($\mu \pm \sigma$)
RF na tf-idf	0.8922 ± 0.0041	0.8915 ± 0.0047
RF na tf-idf + PH	0.8906 ± 0.0047	0.8897 ± 0.0051

Unakrsna validacija preko 10 foldova.

Pod unakrsnom validacijom rezultat je drugačiji: prosečna razlika u tačnosti je zapravo negativna (-0.0016), kombinovani model je bolji u samo 5 od 10 foldova, a upareni t-test daje $p = 0.15$ za tačnost i $p = 0.11$ za makro F1. Dakle, nema statistički značajne razlike. Prividno poboljšanje sa fiksne podele bilo je šum.

Zašto PH karakteristike ne pomažu? Odgovor se vidi u njihovim raspodelama po klasama:



Raspodela dve najznačajnije PH karakteristike po klasama, gotovo identične.


Raspodele su praktično iste za sve tri klase, pa karakteristike ne mogu da razdvoje klase. Uz to, u kombinovanom modelu ukupan udeo svih šest PH karakteristika u značaju slučajne šume je svega oko 1%. Dodavanjem šest neinformativnih kolona uz 500 tf-idf kolona samo unosimo malo šuma.

Do sada smo topologiju gradili iz tf-idf rastojanja suseda, dakle iz semantike, a ne iz same mreže citata. Ostaje najzanimljivije pitanje: da li sama struktura ko-koga-citira nosi signal o klasi?

STRUKTURNA PERZISTENTNA HOMOLOGIJA CITATNIH MREŽA

Ovde gradimo topologiju isključivo iz žica citata. Za svaki rad uzimamo njegovu 2-hop citatnu ego-mrežu (rad, radovi sa kojima je povezan, i njihovi susedi), računamo graf-geodezijsko rastojanje unutar tog podgraфа i nad njim Vietoris-Ripsov perzistentni dijagram. Sada H_1 hvata citatne petlje, obrasce oblika $i \rightarrow a \rightarrow c \rightarrow b \rightarrow i$, odnosno da li se susedi jednog rada i međusobno citiraju.

Zanimljiv detalj: 1-hop ego-mreže su gotovo uvek stabla (nijedna nema H_1 petlju, jer se trougao u perzistenciji odmah "popuni"), pa tek 2-hop okolina otkriva prave petlje. Veličinu podgraфа ograničavamo na 150 radova zbog čvorova sa ogromnim brojem citata.




Strukturni dijagram jedne guste citatne ego-mreže. Geodezijska rastojanja su celobrojna pa se tačke gomilaju; $\times n$ označava koliko klasa se poklopi. Ovaj rad ima preko 200 nezavisnih citatnih petlji.

Za razliku od semantičke PH, strukturne petlje nisu retke: 44% radova ima bar jednu H_1 petlju u svojoj 2-hop citatnoj mreži. Zanimljivo je da strukturne karakteristike i same nose vidljiv signal:

Model	Tačnost	Makro F1
Većinska klasa (referenca)	0.40	–
RF samo na semantičkim PH	0.4108	0.3207
RF samo na strukturnim PH	0.4990	0.4570

Sam topološki signal: strukturna PH je osetno iznad većinske klase.

Strukturna PH sama dostiže tačnost oko 0.50, znatno iznad većinske klase (0.40) i iznad semantičke PH (0.41). Dakle sama mreža citata nosi informaciju o klasi. To se vidi i u raspodeli po klasama: klasa 0 ima mnogo manje citatnih petlji od klasa 1 i 2, jer su joj citatne mreže ređe (prosečan stepen 2.5 naspram 3.8 i 4.0).



Broj petlji i perzistentna entropija H_1 po klasama, gde je klasa 0 vidno stablastija.

Pa ipak, kada strukturne karakteristike dodamo tf-idf-u i proverimo unakrsnom validacijom, rezultat je isti kao ranije:

Model	Tačnost ($\mu \pm \sigma$)	Makro F1 ($\mu \pm \sigma$)
RF na tf-idf	0.8922 ± 0.0041	0.8915 ± 0.0047
RF na tf-idf + strukturna PH	0.8905 ± 0.0048	0.8898 ± 0.0053

Unakrsna validacija: strukturna PH ne pomaže povrh tf-idf-a.

Prosečna razlika je ponovo blago negativna (-0.0017), kombinovani model je bolji u samo 2 od 10 foldova, $p = 0.08$. Ukupan udeo strukturnih karakteristika u značaju šume je oko 1.8%, malo veći nego kod semantičke PH, ali i dalje nedovoljan.


DESKRIPTIVNO POREĐENJE KLASA

Umesto klasifikacije, možemo direktno pitati: da li se tri klase uopšte topološki razlikuju? Za svaku klasu posmatramo njen indukovani citatni podgraf (strukturna strana) i uzorak njenog tf-idf oblaka (semantička strana).

Klasa	Radova	Citata	Pros. stepen	Komponenti
Klasa 0	4103	5212	2.54	842
Klasa 1	7739	14563	3.76	678
Klasa 2	7875	15790	4.01	1124

Strukturni profil citatnih podgrafova po klasama.

Strukturno se klase razlikuju: klasa 0 je najmanja i najređe povezana. Semantički, međutim, tri klase imaju gotovo isti oblik. Njihove H_1 Betti krive (broj petlji tf-idf oblaka u zavisnosti od praga) se skoro poklapaju, sa vrhom oko praga 0.7:



Semantičke H_1 Betti krive tri klase, gotovo identičan topološki profil.

Klase se, dakle, razlikuju po gustini citatne mreže, ali ne i po obliku u semantičkom prostoru. Signal koji izvlačimo iz topologije (gustina povezivanja, sličnost tema) jeste stvaran, ali ga tf-idf već sadrži.

BOGATIJI FEATURE-I, PRETRAGA I OBJEDINJENI MODEL

Do sada su topološki feature-i bili šest skalara (entropija i deskriptori) po čvoru. Prirodno je zapitati se da li bi bogatija reprezentacija ili kombinovanje pristupa promenili zaključak. Idemo u tri pravca. (Kod celog poglavlja, uključujući ova proširenja, je u notebooku `perzistentna_homologija_pubmed.ipynb`.)

Prvi je vektorizacija dijagrama. Umesto sažimanja u entropiju, svaki po-čvor dijagram pretvaramo u *Persistence Image*, zaglađenu 2D sliku po koordinatama (nastanak, trajnost), zasebno za H_0 i H_1 , koju izravnamo u vektor od 50 brojeva. Ovakav mnogo bogatiji opis lokalne topologije ipak ne pomaže: pod unakrsnom validacijom tf-idf ostaje na 0.8922, a uz Persistence Image pada na 0.8902.

Drugi pravac je pretraga po definiciji okoline (1-hop naspram 2-hop) i tipu feature-a (entropija naspram slike), petostrukom unakrsnom validacijom:

Konfiguracija	CV tačnost
tf-idf (baseline)	0.8934
1-hop entropija (6)	0.8908
2-hop entropija (6)	0.8907
1-hop slika (50)	0.8901
2-hop slika (50)	0.8889

Pretraga po okolini i vektorizaciji: nijedna varijanta ne prelazi baseline.

Nijedna konfiguracija ne prevazilazi čist tf-idf. Ni više hopova ni bogatija slika ne otključavaju nov signal.

Treći pokušaj je objedinjeni model: tf-idf plus sve topološke reprezentacije zajedno (semantička entropija, strukturna PH i Persistence Image), ukupno 62 dodatne kolone. Ovaj model je najlošiji od svih: tačnost pada sa 0.8922 na 0.8868. Dodavanjem mnoštva slabo-informativnih, međusobno redundantnih kolona uz 500-dimenzioni tf-idf samo otežavamo slučajnoj šumi da napravi dobre podele.

Ni bogatija vektorizacija ni objedinjeni model, dakle, ne menjaju zaključak: povrh tf-idf-a nijedan od isprobanih topoloških pristupa ne donosi robusno poboljšanje. Razlog je to što radovi obično citiraju druge radove iz iste oblasti, pa njihova povezanost citatima i raspored u prostoru reči govore uglavnom o temi rada, a tu informaciju tf-idf vektor već sadrži. Topološke karakteristike zato ne daju ništa novo, samo istu informaciju u drugom obliku.

ZAKLJUČAK

Prošli smo kroz dve najčešće metode topološke analize podataka, perzistentnu homologiju i mapper. Na jednostavnim, čisto geometrijskim primerima (kružnica, sfera, torus) perzistentna homologija bez greške razlikuje oblike, jer tamo topološka struktura zaista postoji i nosi svu informaciju. Na stvarnom skupu poput PubMed-a slika je drugačija: nijedna od metoda nije nadmašila običan tf-idf, ni mapper ni perzistentna homologija. Razlog nije u tome što su metode loše, već što u ovim podacima ne dobijamo ništa što tf-idf već ne zna.

Glavna pouka je da TDA ne pomaže svakom klasifikatoru sam po sebi. Isplati se tek kada u podacima postoji topološka struktura koju jednostavnije reprezentacije ne hvataju. Kada takve strukture nema, dodatni topološki feature-i samo unose šum.

Ipak, to ne znači da oblast nema budućnost. Topološka analiza podataka je još uvek mlada i ima visok prag ulaska jer traži solidne osnove algebarske topologije, pa se delom zato razvija sporije od drugih modernih pristupa. Za sada se isplati koristiti je ciljano, tamo gde struktura podataka nije očigledna, a ne kao podrazumevani dodatak svakom modelu.